

# 张量分解

彭毅


## » 基本概念及记号

# 基本概念及记号


- ▶ 张量 (tensor)
  - 多维数组



一阶张量  
(向量)



二阶张量  
(矩阵)





三阶张量

# 基本概念及记号

## 张量空间

- 由若干个向量空间中的基底的外积张成的空间




向量的外积和内积

# 基本概念及记号

## ► 阶 (order/ways/modes/**rank**)

◦ 张成所属张量空间的向量空间的个数


- 一阶张量 (向量) :  $\mathbf{x} = \{x_i\}$
- 二阶张量 (矩阵) :  $\mathbf{X} = \{x_{ij}\}$
- 三阶或更高阶张量:  $\mathcal{X} = \{x_{ij\dots k}\}$
- 零阶张量 (数量) :  $x$




三阶张量:  $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$

# 基本概念及记号


## ► 纤维 (fiber)



mode-1 (列)  
纤维:  $\mathbf{x}_{:jk}$




mode-2 (行)  
纤维:  $\mathbf{x}_{i:k}$




mode-3 (管)  
纤维:  $\mathbf{x}_{ij:}$

# 基本概念及记号


## ► 切片 (slice)



水平切片:  $\mathbf{X}_{i::}$



侧面切片:  $\mathbf{X}_{:,j:}$



正面切片:  $\mathbf{X}_{::k} (\mathbf{X}_k)$

# 基本概念及记号

## ▶ 内积和范数

- 设  $\mathcal{X}, \mathcal{Y} \in \square^{I_1 \times I_2 \times \cdots \times I_N}$

内积:

$$\langle \mathcal{X}, \mathcal{Y} \rangle = \sum_{i_1=1}^{I_1} \sum_{i_2=1}^{I_2} \cdots \sum_{i_N=1}^{I_N} x_{i_1 i_2 \cdots i_N} y_{i_1 i_2 \cdots i_N}$$

(Frobenius) 范数:

$$\|\mathcal{X}\| = \sqrt{\langle \mathcal{X}, \mathcal{X} \rangle} = \sqrt{\sum_{i_1=1}^{I_1} \sum_{i_2=1}^{I_2} \cdots \sum_{i_N=1}^{I_N} x_{i_1 i_2 \cdots i_N}^2}$$




# 基本概念及记号

## ▶ 秩一张量 / 可合张量

- N阶张量  $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times \cdots \times I_N}$  是一个秩一张量，如果它能被写成N个向量的外积，即

$$\mathcal{X} = \mathbf{a}^{(1)} \circ \mathbf{a}^{(2)} \circ \cdots \circ \mathbf{a}^{(N)}$$



$$\text{三阶秩一张量: } \mathcal{X} = \mathbf{a} \circ \mathbf{b} \circ \mathbf{c}$$


# 基本概念及记号

## ▶ （超）对称和（超）对角

- 立方张量：各个mode的长度相等
- 对称：一个立方张量是对称的，如果其元素在下标的任意排列下是常数。如一个三阶立方张量是超对称的，如果

$$x_{ijk} = x_{ikj} = x_{jik} = x_{jki} = x_{kij} = x_{kji}, \forall i, j, k$$


- 对角：仅当  $i_1 = i_2 = \dots = i_N$  时， $x_{i_1 i_2 \dots i_N} \neq 0$



张量的（超）对角线

# 基本概念及记号

- ▶ 展开（matricization/unfolding/flattening）
  - 将N阶张量  $\mathcal{X}$  沿mode-n展开成一个矩阵  $\mathbf{X}_{(n)}$



←  $\mathbf{X}_{(1)}$   
↓

三阶张量的mode-1展开

# 基本概念及记号

## ► n-mode (矩阵) 乘积

- 一个张量  $\mathcal{X} \in \square^{I_1 \times I_2 \times \cdots \times I_N}$  和一个矩阵  $\mathbf{U} \in \square^{J \times I_n}$  的n-mode 乘积  $(\mathcal{X} \times_n \mathbf{U}) \in \square^{I_1 \times \cdots \times I_{n-1} \times J \times I_{n+1} \times \cdots \times I_N}$ , 其元素定义为

$$(\mathcal{X} \times_n \mathbf{U})_{i_1 \cdots i_{n-1} j i_{n+1} \cdots i_N} = \sum_{i_n=1}^{I_n} x_{i_1 i_2 \cdots i_N} u_{ji_n}$$

- 这个定义可以写成沿mode-n展开的形式

$$\mathcal{Y} = \mathcal{X} \times_n \mathbf{U} \Leftrightarrow \mathbf{Y}_{(n)} = \mathbf{U} \mathbf{X}_{(n)}$$

- 性质:  $\mathcal{X} \times_m \mathbf{A} \times_n \mathbf{B} = \mathcal{X} \times_n \mathbf{B} \times_m \mathbf{A}, m \neq n$

$$\mathcal{X} \times_n \mathbf{A} \times_n \mathbf{B} = \mathcal{X} \times_n (\mathbf{BA})$$

# 基本概念及记号

## ► n-mode (向量) 乘积

- 一个张量  $\mathcal{X} \in \square^{I_1 \times I_2 \times \cdots \times I_N}$  和一个向量  $\mathbf{v} \in \square^{I_n}$  的n-mode 乘积  $(\mathcal{X} \bar{\times}_n \mathbf{v}) \in \square^{I_1 \times \cdots \times I_{n-1} \times I_{n+1} \times \cdots \times I_N}$ , 其元素定义为

$$(\mathcal{X} \bar{\times}_n \mathbf{v})_{i_1 \cdots i_{n-1} i_{n+1} \cdots i_N} = \sum_{i_n=1}^{I_n} x_{i_1 i_2 \cdots i_N} v_{i_n}$$

- 性质:

$$\mathcal{X} \bar{\times}_m \mathbf{a} \bar{\times}_n \mathbf{b} = (\mathcal{X} \bar{\times}_m \mathbf{a}) \bar{\times}_{n-1} \mathbf{b} = (\mathcal{X} \bar{\times}_n \mathbf{b}) \bar{\times}_m \mathbf{a}, m < n$$

# 基本概念及记号

## ► 矩阵的Kronecker乘积

- $\mathbf{A} \in \mathbb{R}^{I \times J}, \mathbf{B} \in \mathbb{R}^{K \times L}$ , 则

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & a_{12}\mathbf{B} & \cdots & a_{1J}\mathbf{B} \\ a_{21}\mathbf{B} & a_{22}\mathbf{B} & \cdots & a_{2J}\mathbf{B} \\ \vdots & \vdots & \ddots & \vdots \\ a_{I1}\mathbf{B} & a_{I2}\mathbf{B} & \cdots & a_{IJ}\mathbf{B} \end{bmatrix} \in \mathbb{R}^{IK \times JL}$$

- 性质:  $(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = (\mathbf{AC}) \otimes (\mathbf{BD})$

$$(\mathbf{A} \otimes \mathbf{B})^+ = \mathbf{A}^+ \otimes \mathbf{B}^+$$

# 基本概念及记号

## ▶ 矩阵的Kronecker乘积

- 矩阵的Kronecker积还和张量和矩阵的n-mode乘积有如下关系

$$\mathcal{Y} = \mathcal{X} \times_1 \mathbf{A}^{(1)} \cdots \times_N \mathbf{A}^{(N)} \Leftrightarrow$$

$$\mathbf{Y}_{(n)} = \mathbf{A}^{(n)} \mathbf{X}_{(n)} \left( \mathbf{A}^{(N)} \otimes \cdots \otimes \mathbf{A}^{(n+1)} \otimes \mathbf{A}^{(n-1)} \otimes \cdots \otimes \mathbf{A}^{(1)} \right)^T$$

# 基本概念及记号

## ▶ 矩阵的Khatri-Rao乘积

- $\mathbf{A} \in \mathbb{R}^{I \times K}, \mathbf{B} \in \mathbb{R}^{J \times K}$  , 则

$$\mathbf{A} \boxtimes \mathbf{B} = [\mathbf{a}_1 \otimes \mathbf{b}_1 \quad \mathbf{a}_2 \otimes \mathbf{b}_2 \quad \cdots \quad \mathbf{a}_K \otimes \mathbf{b}_K] \in \mathbb{R}^{IJ \times K}$$

- 性质:  $\mathbf{A} \boxtimes \mathbf{B} \boxtimes \mathbf{C} = (\mathbf{A} \boxtimes \mathbf{B}) \boxtimes \mathbf{C} = \mathbf{A} \boxtimes (\mathbf{B} \boxtimes \mathbf{C})$



# 基本概念及记号

## ► 矩阵的Hadamard乘积

- $\mathbf{A} \in \mathbb{R}^{I \times J}, \mathbf{B} \in \mathbb{R}^{I \times J}$ , 则

$$\mathbf{A} * \mathbf{B} = \begin{bmatrix} a_{11}b_{11} & a_{12}b_{12} & \cdots & a_{1J}b_{1J} \\ a_{21}b_{21} & a_{22}b_{22} & \cdots & a_{2J}b_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ a_{I1}b_{I1} & a_{I2}b_{I2} & \cdots & a_{IJ}b_{IJ} \end{bmatrix} \in \mathbb{R}^{I \times J}$$

- 性质:  $(\mathbf{A} \oslash \mathbf{B})^T (\mathbf{A} \oslash \mathbf{B}) = (\mathbf{A}^T \mathbf{A}) * (\mathbf{B}^T \mathbf{B})$

$$(\mathbf{A} \oslash \mathbf{B})^+ = \left( (\mathbf{A}^T \mathbf{A}) * (\mathbf{B}^T \mathbf{B}) \right)^+ (\mathbf{A} \oslash \mathbf{B})^T$$

## » CP分解

# CP分解

## ▶ CP分解的其他名字


- Polyadic Form of a Tensor, Hitchcock, 1927
- PARAFAC(Parallel Factors), Harshman, 1970
- CANDECOMP/CAND(Canonical decomposition), Carroll & Chang, 1970
- Topographic Components Model, Möcks, 1988
- CP(CANDECOMP/PARAFAC), Kiers, 2000

# CP分解

## ▶ CP分解的张量形式

- 将一个张量表示成有限个秩一张量之和，比如一个三阶张量可以分解为

$$\mathcal{X} \approx \mathbf{A}, \mathbf{B}, \mathbf{C} = \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r$$



三阶张量的CP分解

# CP分解

## ▶ CP分解的矩阵形式

- 因子矩阵：秩一张量中对应的向量组成的矩阵，如

$$\mathbf{A} = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_R]$$

- 利用因子矩阵，一个三阶张量的CP分解可以写成展开形式

$$\mathbf{X}_{(1)} \approx \mathbf{A}(\mathbf{C} \boxtimes \mathbf{B})^T$$

$$\mathbf{X}_{(2)} \approx \mathbf{B}(\mathbf{C} \boxtimes \mathbf{A})^T$$

$$\mathbf{X}_{(3)} \approx \mathbf{C}(\mathbf{B} \boxtimes \mathbf{A})^T$$


# CP分解

## ▶ CP分解的切片形式

- 三阶张量的CP分解有时按（正面）切片写成如下形式：

$$\mathbf{X}_k \approx \mathbf{A} \mathbf{D}^{(k)} \mathbf{B}^T$$

其中  $\mathbf{D}^{(k)} \equiv \text{diag}(\mathbf{c}_{k:})$



三阶张量CP分解的正面切片形式

# CP分解

## ▶ 带权CP分解

- 为了计算方便，通常假设因子矩阵的列是单位长度的，从而需要引入一个权重向量  $\lambda \in \mathbb{R}^R$ ，使CP分解变为

$$\mathcal{X} \approx \lambda; \mathbf{A}, \mathbf{B}, \mathbf{C} \equiv \sum_{r=1}^R \lambda_r \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r$$

- 对于高阶张量，有

$$\mathcal{X} \approx \llbracket \lambda; \mathbf{A}^{(1)}, \mathbf{A}^{(2)}, \dots, \mathbf{A}^{(N)} \rrbracket \equiv \sum_{r=1}^R \lambda_r \mathbf{a}_r^{(1)} \circ \mathbf{a}_r^{(2)} \circ \dots \circ \mathbf{a}_r^{(N)}$$

其展开形式为

$$\mathbf{X}_{(n)} \approx \mathbf{A}^{(n)} \text{diag}(\lambda) \left( \mathbf{A}^{(N)} \square \dots \square \mathbf{A}^{(n+1)} \square \mathbf{A}^{(n-1)} \square \dots \square \mathbf{A}^{(1)} \right)^T$$

# CP分解

## 张量的秩和秩分解

- 张量  $\mathcal{X}$  的秩定义为用秩一张量之和来精确表示  $\mathcal{X}$  所需要的秩一张量的最少个数，记为  $\text{rank}(\mathcal{X})$

- 秩分解：

$$\mathcal{X} = \sum_{r=1}^{\text{rank}(\mathcal{X})} \mathbf{a}_r^{(1)} \circ \mathbf{a}_r^{(2)} \circ \dots \circ \mathbf{a}_r^{(N)}$$

可见秩分解是一个特殊的CP分解，对应于矩阵的SVD

- 目前还没有方法能够直接求解一个任意给定张量的秩，这被证明是一个NP-hard问题



# CP分解

## 张量的秩

- 不同于矩阵的秩，高阶张量的秩在实数域和复数域上不一定相同。例如一个三阶张量 $\mathcal{X}$

$$\mathbf{X}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad \mathbf{X}_2 = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$$

在实数域内进行秩分解得到的因子矩阵为

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \end{bmatrix} \quad \mathbf{B} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \quad \mathbf{C} = \begin{bmatrix} 1 & 1 & 0 \\ -1 & 1 & 1 \end{bmatrix}$$

而在复数域内进行分解得到的因子矩阵为

$$\mathbf{A} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -i & i \end{bmatrix} \quad \mathbf{B} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix} \quad \mathbf{C} = \begin{bmatrix} 1 & 1 \\ i & -i \end{bmatrix}$$

# CP分解

## ▶ 张量的低秩近似

- 相对于矩阵的SVD来说，高阶张量的秩分解唯一性不需要正交性条件保证，只需满足：

$$\sum_{n=1}^N k_{\mathbf{A}^{(n)}} \geq 2R + N - 1$$

这里  $k_{\mathbf{A}}$  表示矩阵  $\mathbf{A}$  的k-秩：任意k列都线性无关的最大的k

# CP分解

## ▶ 张量的低秩近似

- 然而在低秩近似方面，高阶张量的性质比矩阵SVD差
  - Kolda给出了一个例子，一个立方张量的最佳秩-1近似并不包括在其最佳秩-2近似中，这说明张量的秩-k近似无法渐进地得到
  - 下面的例子说明，张量的“最佳”秩-k近似甚至**不一定存在**


$$\mathcal{X} = \mathbf{a}_1 \circ \mathbf{b}_1 \circ \mathbf{c}_2 + \mathbf{a}_1 \circ \mathbf{b}_2 \circ \mathbf{c}_1 + \mathbf{a}_2 \circ \mathbf{b}_1 \circ \mathbf{c}_1$$

$$\mathcal{Y} = \alpha \left( \mathbf{a}_1 + \frac{1}{\alpha} \mathbf{a}_2 \right) \circ \left( \mathbf{b}_1 + \frac{1}{\alpha} \mathbf{b}_2 \right) \circ \left( \mathbf{c}_1 + \frac{1}{\alpha} \mathbf{c}_2 \right) - \alpha \mathbf{a}_1 \circ \mathbf{b}_1 \circ \mathbf{c}_1$$

# CP分解

## 张量的低秩近似

- 退化：如果一个张量能够被一系列的低秩张量任意逼近
- 边缘秩（border rank）：能够任意逼近一个张量的最少的成分个数



一个秩为2的张量序列收敛到一个秩3张量

# CP分解

## ▶ CP分解的计算

- 分解成多少个秩一张量（成分）之和？
  - 通常的做法是从1开始尝试，知道碰到一个“好”的结果为止
  - 如果有较强的应用背景和先验信息，可以预先指定
- 对于给定的成分数目，怎么求解CP分解？
  - 目前仍然没有一个完美的解决方案
  - 从效果来看，交替最小二乘（Alternating Least Square）是一类比较有效的算法

# CP分解

## ▶ CP分解的计算

- 以一个三阶张量  $\mathcal{X}$  为例，假定成分个数  $R$  已知，目标为

$$\min_{\hat{\mathcal{X}}} \|\mathcal{X} - \hat{\mathcal{X}}\| \quad \text{s.t.} \quad \hat{\mathcal{X}} = \sum_{r=1}^R \lambda_r \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r = \boldsymbol{\lambda}; \mathbf{A}, \mathbf{B}, \mathbf{C}$$

- 作为ALS的一个子问题，固定  $\mathbf{B}$  和  $\mathbf{C}$ ，求解

$$\min_{\mathbf{A}} \left\| \mathbf{X}_{(1)} - \mathbf{A} \text{diag}(\boldsymbol{\lambda}) (\mathbf{C} \boxtimes \mathbf{B})^T \right\|_F$$

$$\text{得 } \mathbf{A} \text{diag}(\boldsymbol{\lambda}) = \mathbf{X}_{(1)} \left[ (\mathbf{C} \boxtimes \mathbf{B})^T \right]^+ = \mathbf{X}_{(1)} (\mathbf{C} \boxtimes \mathbf{B}) (\mathbf{C}^T \mathbf{C} * \mathbf{B}^T \mathbf{B})^+$$

再通过归一化分别求出  $\mathbf{A}$  和  $\boldsymbol{\lambda}$

# CP分解

## ▶ CP分解的计算

- ALS算法并不能保证收敛到一个极小点，甚至不一定能收敛到稳定点，它只能找到一个目标函数不再下降的点
- 算法的初始化可以是随机的，也可以将因子矩阵初始化为对应展开的奇异向量，如将 $\mathbf{A}$  初始化为 $\mathcal{X}_{(1)}$ 的前  $R$  个左奇异向量

# CP分解

- ▶ CP分解的应用
  - 计量心理学
  - 语音分析
  - 化学计量学
  - 独立成分分析
  - 神经科学
  - 数据挖掘
  - 高维算子近似
  - 随即偏微分方程
  - .....



## » Tucker分解

# Tucker分解

- ▶ Tucker分解的其他名字
  - Three-mode factor analysis(3MFA/Tucker3), Tucker, 1966
  - Three-mode principal component analysis(3MPCA), Kroonenberg & De Leeuw, 1980
  - N-mode principal components analysis, Kapteyn et al., 1986
  - Higher-order SVD(HOSVD), De Lathauwer et al., 2000
  - N-mode SVD, Vasilescu and Terzopoulos, 2002

# Tucker分解

## ▶ Tucker分解

- Tucker分解是一种高阶的主成分分析，它将一个张量表示成一个核心（core）张量沿每一个mode乘上一个矩阵。

对于三阶张量  $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$  来说，其Tucker分解为


$$\mathcal{X} \approx \mathcal{G}; \mathbf{A}, \mathbf{B}, \mathbf{C} = \mathcal{G} \times_1 \mathbf{A} \times_2 \mathbf{B} \times_3 \mathbf{C} = \sum_{p=1}^P \sum_{q=1}^Q \sum_{r=1}^R g_{pqr} \mathbf{a}_p \circ \mathbf{b}_q \circ \mathbf{c}_r$$

- 因子矩阵  $\mathbf{A} \in \mathbb{R}^{I \times P}$ ,  $\mathbf{B} \in \mathbb{R}^{J \times Q}$ ,  $\mathbf{C} \in \mathbb{R}^{K \times R}$  通常是正交的，可以视为沿相应mode的主成分

# Tucker分解

## ▶ Tucker分解

- 容易看出，CP分解是Tucker分解的一种特殊形式：如果核心张量  $G$  是对角的，且  $P = Q = R$ ，则Tucker分解就退化成了CP分解



三阶张量的Tucker分解

# Tucker分解

## ▶ Tucker分解的矩阵形式

- 三阶Tucker分解的展开形式为

$$\mathbf{X}_{(1)} \approx \mathbf{A} \mathbf{G}_{(1)} (\mathbf{C} \otimes \mathbf{B})^T$$

$$\mathbf{X}_{(2)} \approx \mathbf{B} \mathbf{G}_{(2)} (\mathbf{C} \otimes \mathbf{A})^T$$

$$\mathbf{X}_{(3)} \approx \mathbf{C} \mathbf{G}_{(3)} (\mathbf{B} \otimes \mathbf{A})^T$$

- Tucker分解可以推广到高阶张量

$$\mathcal{X} \approx \mathcal{G} \times_1 \mathbf{A}^{(1)} \times_2 \mathbf{A}^{(2)} \cdots \times_N \mathbf{A}^{(N)} = \boxed{\boxed{\mathcal{G}; \mathbf{A}^{(1)}, \mathbf{A}^{(2)}, \dots, \mathbf{A}^{(N)}}}$$

$$\mathbf{X}_{(n)} \approx \mathbf{A}^{(n)} \mathbf{G}_{(n)} \left( \mathbf{A}^{(N)} \otimes \cdots \otimes \mathbf{A}^{(n+1)} \otimes \mathbf{A}^{(n-1)} \otimes \cdots \otimes \mathbf{A}^{(1)} \right)^T$$

# Tucker分解

## ▶ Tucker2和Tucker1

- 对于三阶张量固定一个因子矩阵为单位阵，就得到Tucker分解一个重要的特例：Tucker2。例如固定  $\mathbf{C} = \mathbf{I}$ ，则

$$\mathcal{X} \approx \mathcal{G} \times_1 \mathbf{A} \times_2 \mathbf{B} = \mathcal{G}; \mathbf{A}, \mathbf{B}, \mathbf{I}$$

- 进一步，固定两个因子矩阵，就得到了Tucker1，例如令第二、三个因子矩阵为单位阵，则Tucker分解就退化成了普通的PCA

$$\mathcal{X} \approx \mathcal{G} \times_1 \mathbf{A} = \mathcal{G}; \mathbf{A}, \mathbf{I}, \mathbf{I} \Leftrightarrow \mathbf{X}_{(1)} = \mathbf{A} \mathbf{G}_{(1)}$$

# Tucker分解

## 张量的n-秩近似


- 一个N阶张量 $\mathcal{X}$ 的n-秩定义为

$$\text{rank}_n(\mathcal{X}) = \text{rank}(\mathbf{X}_{(n)})$$

- 若设  $\text{rank}_n(\mathcal{X}) = R_n, n = 1, \dots, N$ ，则  $\mathcal{X}$  叫做一个秩- $(R_1, R_2, \dots, R_N)$  张量
- 如果  $\text{rank}_n(\mathcal{X}) = R_n, n = 1, \dots, N$ ，则很容易得到  $\mathcal{X}$  的一个精确秩- $(R_1, R_2, \dots, R_N)$  Tucker分解；然而如果至少有一个  $n$  使得  $\text{rank}_n(\mathcal{X}) > R_n$ ，则通过Tucker分解得到的就是  $\mathcal{X}$  的一个秩- $(R_1, R_2, \dots, R_N)$  近似

# Tucker分解

## 张量的n-秩近似



截断的Tucker分解：秩- $(R_1, R_2, R_3)$  近似



# Tucker分解

## ▶ 张量的 $n$ -秩近似

- 对于固定的 $n$ -秩，Tucker分解的唯一性不能保证，所以需要添加其他的约束
- 通常要求核心张量是“简单”的，如各个mode的主成分之间尽量不发生相互作用（稀疏性），或者其他的“简单性”约束

# Tucker分解

## ▶ Tucker分解的计算

- HOSVD: 利用SVD对每个mode做一次Tucker1分解（截断或者不截断）
- HOSVD不能保证得到一个较好的近似，但HOSVD的结果可以作为一个其他迭代算法（如HOOI）的很好的初始解

# Tucker分解

## ▶ Tucker分解的计算

- 为了导出HOOI迭代算法，先考虑目标函数

$$\begin{aligned} & \left\| \mathcal{X} - \llbracket G; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket \right\| \\ &= \left\| \text{vec}(\mathcal{X}) - \left( \mathbf{A}^{(N)} \otimes \dots \otimes \mathbf{A}^{(1)} \right) \text{vec}(G) \right\| \end{aligned}$$

- 从而  $G$  应该满足

$$G = \mathcal{X} \times_1 \mathbf{A}^{(1)\text{T}} \dots \times_N \mathbf{A}^{(N)\text{T}}$$

# Tucker分解

## ▶ Tucker分解的计算

- 目标函数的平方变为

$$\begin{aligned}& \left\| \mathcal{X} - \begin{bmatrix} G; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \end{bmatrix} \right\|^2 \\&= \|\mathcal{X}\|^2 - 2 \left\langle \mathcal{X}, \begin{bmatrix} G; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \end{bmatrix} \right\rangle + \left\| \begin{bmatrix} G; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \end{bmatrix} \right\|^2 \\&= \|\mathcal{X}\|^2 - 2 \left\langle \mathcal{X} \times_1 \mathbf{A}^{(1)\mathrm{T}} \cdots \times_N \mathbf{A}^{(N)\mathrm{T}}, G \right\rangle + \|G\|^2 \\&= \|\mathcal{X}\|^2 - 2 \langle G, G \rangle + \|G\|^2 \\&= \|\mathcal{X}\|^2 - \left\| \mathcal{X} \times_1 \mathbf{A}^{(1)\mathrm{T}} \cdots \times_N \mathbf{A}^{(N)\mathrm{T}} \right\|^2\end{aligned}$$

# Tucker分解

## ▶ Tucker分解的计算

- 所以问题可以进行如下转化

$$\min \left\| \mathcal{X} - \begin{bmatrix} \mathbf{G} \\ \mathbf{A}^{(1)} \end{bmatrix}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \right\|$$

$$\Leftrightarrow \max \left\| \mathcal{X} \times_1 \mathbf{A}^{(1)\text{T}} \dots \times_N \mathbf{A}^{(N)\text{T}} \right\|$$

- 利用交替求解的思想，问题变为解如下子问题

$$\max \left\| \mathbf{A}^{(n)\text{T}} \mathbf{W} \right\|$$

$$\text{s.t. } \mathbf{W} = \mathbf{X}_{(n)} \left( \mathbf{A}^{(N)} \otimes \dots \otimes \mathbf{A}^{(n+1)} \otimes \mathbf{A}^{(n-1)} \dots \otimes \mathbf{A}^{(1)} \right)$$

这个问题可以通过令  $\mathbf{A}^{(n)}$  为  $\mathbf{W}$  的前  $R_n$  个左奇异值向量来解决

# Tucker分解

- ▶ Tucker分解的应用
  - 化学分析
  - 计量心理学
  - 信号处理
  - 机器视觉（面部、动作）
  - 数据压缩
  - 纹理生成
  - 数据挖掘
  - 环境和网络建模
  - .....

**欢迎大家提出宝贵建议**